

# UNIVERSIDAD AUTÓNOMA DE BAJA CALIFORNIA

## FACULTAD DE CONTADURÍA Y ADMINISTRACIÓN



## Ciencia de datos

### Proyecto Final: Ciencia de Datos Aplicada a la Predicción de Fuga de Clientes

PRESENTADO POR LOS ALUMNOS

**De La Cruz Ramirez Jeremy Yael**

**Garnica Mendoza Jesus Alexis**

**Ramirez Cardenas Luis Armando**

NOMBRE DEL DOCENTE



**Josue Miguel Flores Parra**

NOMBRE DE LA CARRERA

**Inteligencia de Negocios**

FECHA

**03/06/2026**



# Índice

|                                                                               |           |
|-------------------------------------------------------------------------------|-----------|
| <b>COMPRENSIÓN DEL PROBLEMA.....</b>                                          | <b>1</b>  |
| 1.1. Descripción del Problema.....                                            | 1         |
| 1.2. Importancia del Análisis.....                                            | 2         |
| 1.3. Objetivos del Proyecto.....                                              | 2         |
| <b>COMPRENSIÓN DE LOS DATOS (DATA UNDERSTANDING).....</b>                     | <b>4</b>  |
| 2.1. Origen del Dataset.....                                                  | 4         |
| 2.2. Descripción de Variables Utilizadas para el Modelado.....                | 4         |
| 2.3. Análisis Exploratorio de Datos (EDA).....                                | 5         |
| 2.4. Hallazgos de las Gráficas y Visualizaciones.....                         | 6         |
| <b>PREPARACIÓN DE LOS DATOS (DATA PREPARATION).....</b>                       | <b>7</b>  |
| 3.1. Selección de Variables y Filtrado.....                                   | 7         |
| 3.2. Tratamiento Técnico de Valores Nulos.....                                | 7         |
| 3.3. Codificación de Variables Categóricas (Encoding).....                    | 7         |
| 3.4. Transformación de Datos y División Estratificada (Train/Test Split)..... | 8         |
| 3.5. Normalización y Escalamiento Estándar.....                               | 8         |
| <b>MODELADO Y EXPERIMENTACIÓN (MODELING).....</b>                             | <b>10</b> |
| 4.1. Algoritmos Utilizados.....                                               | 10        |
| 4.2. Parámetros Utilizados y Experimentación Realizada.....                   | 10        |
| 4.3. Resultados Obtenidos (Leaderboard de Modelos).....                       | 11        |
| Tabla 4.1: Leaderboard General de Experimentos.....                           | 12        |
| 4.4. Evidencia Técnica de la Experimentación.....                             | 14        |
| <b>EVALUACIÓN.....</b>                                                        | <b>15</b> |
| 5.1. Métricas Obligatorias del Modelo Campeón.....                            | 15        |
| 5.2. Gráficas Comparativas y Diagnósticas.....                                | 15        |
| 5.3. Interpretación de Resultados y Comparación entre Modelos.....            | 16        |
| 5.4. Análisis de Errores (Matriz de Confusión).....                           | 17        |
| <b>CONCLUSIONES.....</b>                                                      | <b>19</b> |
| ¿Qué modelo obtuvo mejor desempeño?.....                                      | 19        |
| ¿Qué parámetros mejoraron resultados?.....                                    | 19        |
| ¿Existió overfitting?.....                                                    | 19        |
| ¿Qué limitaciones encuentran?.....                                            | 19        |
| ¿Qué aprendieron del proyecto?.....                                           | 20        |
| <b>CONCLUSIÓN FINAL.....</b>                                                  | <b>21</b> |
| REFERENCIAS.....                                                              | 22        |

# COMPRENSIÓN DEL PROBLEMA

## 1.1. Descripción del Problema

En el dinámico y altamente competitivo sector de las telecomunicaciones modernas, la retención de suscriptores se ha consolidado como uno de los desafíos operativos y financieros más críticos para la sostenibilidad de las organizaciones. Debido a la madurez del mercado global, la homogeneidad en la oferta de servicios y las facilidades regulatorias que permiten a los usuarios cambiar de proveedor de manera ágil —como la portabilidad numérica inmediata—, las tasas de deserción de clientes, fenómeno estadístico y comercial internacionalmente conocido como Churn, se han disparado de manera alarmante. Desde la perspectiva de la economía de la empresa y la gestión de la relación con el cliente (CRM), el impacto financiero de esta fuga es severo y multidimensional.

Por un lado, cada suscriptor que cancela su servicio representa una interrupción inmediata en el flujo de caja operativo mensual de la compañía, afectando de manera directa el Valor de Vida del Cliente. Por otro lado, se genera una destrucción del Retorno de Inversión debido a que la adquisición de un usuario nuevo implica un desembolso sustancial conocido como Costo de Adquisición de Clientes. Este costo abarca desde campañas de marketing digital y comisiones de la fuerza de ventas, hasta el despliegue físico de infraestructura de red en el domicilio del usuario. Cuando un cliente abandona la empresa antes de cumplir su periodo de amortización contractual, la organización se ve forzada a absorber el costo de adquisición como una pérdida neta no recuperada en su estado de resultados. Actualmente, la organización carece de un mecanismo analítico que le permita anticiparse a este fenómeno, lo que condena a las gerencias a tomar decisiones operativas de forma reactiva, interviniendo únicamente cuando el usuario ya ha iniciado su trámite formal de cancelación, un punto de inflexión comercial donde las probabilidades de rescate son mínimas y sumamente costosas.

## **1.2. Importancia del Análisis**

La relevancia de implementar un proyecto integrador de Ciencia de Datos basado en analítica predictiva radica en la necesidad imperativa de migrar de un modelo de gestión comercial reactivo hacia uno proactivo y personalizado. Bajo los esquemas tradicionales de retención, las empresas sufren de una marcada ineficiencia en el uso de sus recursos financieros. Al esperar a que el cliente se comuniqué con el centro de atención telefónica para manifestar su inconformidad o solicitar su baja, la ventana de negociación se reduce drásticamente, provocando que las contraofertas de última hora sean percibidas como medidas desesperadas de baja efectividad.

Asimismo, la falta de segmentación predictiva empuja a las direcciones comerciales a dispersar presupuestos de retención de manera masiva e indiscriminada a bases de datos completas, otorgando descuentos generalizados o actualizaciones de equipo. Esto genera una doble ineficiencia financiera en la operación, puesto que se gasta presupuesto subsidiando a clientes leales que no tenían intenciones reales de abandonar la compañía y, simultáneamente, se envían estímulos insuficientes a los usuarios que sí presentaban un riesgo inminente de abandono. Mediante la aplicación de algoritmos de Aprendizaje Automático, la importancia de este análisis se traduce en un impacto directo a la rentabilidad corporativa. Al procesar variables históricas de consumo, contratos y costos, el modelo actúa como un sistema de alerta temprana que permite ejecutar campañas quirúrgicas de fidelización, inyectando incentivos económicos o de servicio únicamente en los eslabones de la cadena de clientes con alta probabilidad matemática de deserción, optimizando con precisión el presupuesto operativo de la organización.

## **1.3. Objetivos del Proyecto**

Para guiar el desarrollo técnico e institucional de este proyecto integrador bajo el estándar CRISP-DM, se ha definido como objetivo general desarrollar, evaluar e implementar un modelo predictivo de aprendizaje supervisado enfocado en la clasificación binaria utilizando el lenguaje de programación Python, el cual sea capaz de identificar anticipadamente y con un alto nivel de confiabilidad estadística a los clientes con mayor riesgo de fuga en la compañía de telecomunicaciones.

En el ámbito de las metas operativas y analíticas, el proyecto se divide en cuatro objetivos específicos claramente delimitados. En primer lugar, se busca auditar e integrar los datos mediante un Análisis Exploratorio de Datos exhaustivo sobre el dataset histórico de IBM para descubrir patrones comerciales ocultos y corregir inconsistencias o nulos en variables financieras críticas. En segundo lugar, se estructurará la ingeniería de características aplicando técnicas de transformación de datos, codificación de variables categóricas mediante One-Hot Encoding y normalización escalar para habilitar el procesamiento algebraico de los algoritmos sin sesgos dimensionales. Como tercer componente, se ejecutará una experimentación iterativa que someterá el dataset a un diseño experimental de clasificación comparando tres familias de algoritmos distintos bajo nueve configuraciones de hiper parámetros. Finalmente, el cuarto objetivo específico se orienta a optimizar el modelo final con un enfoque netamente de negocio, evaluando los modelos mediante métricas de control robustas que prioricen el balance armónico del F1-Score y la optimización del Recall para mitigar al máximo el costo financiero derivado de los clientes en riesgo no detectados por el sistema.

# **COMPRENSIÓN DE LOS DATOS (DATA UNDERSTANDING)**

## **2.1. Origen del Dataset**

Para garantizar el realismo y el rigor analítico del proyecto integrador, se seleccionó el conjunto de datos denominado Telco Customer Churn, el cual fue diseñado originalmente de forma estratégica por el equipo de científicos de datos de IBM Cloud Pak for Data. Este dataset se ha consolidado a nivel internacional como uno de los conjuntos de referencia más utilizados en plataformas académicas y de competencia como Kaggle para el desarrollo de soluciones analíticas en la industria de las telecomunicaciones. La información fue extraída en su formato bruto directamente desde el repositorio oficial de IBM en GitHub, registrando el comportamiento histórico y el estado de un total de 7,043 clientes independientes, lo que proporciona un volumen de muestra estadísticamente representativo para el entrenamiento de los modelos algorítmicos.

## **2.2. Descripción de Variables Utilizadas para el Modelado**

El conjunto de datos procesado está compuesto por una matriz original de 21 variables que describen las características demográficas, los servicios contratados y el estatus financiero de cada usuario. Tras realizar la limpieza inicial, las variables fundamentales utilizadas para estructurar el aprendizaje de los modelos predictivos se clasifican de la siguiente manera:

- tenure: Variable numérica continua que registra la antigüedad del cliente expresada en la cantidad de meses que ha permanecido activo con la compañía de telecomunicaciones.
- MonthlyCharges: Variable numérica continua que indica el monto financiero fijo que se le factura al usuario de manera mensual por los servicios contratados.
- TotalCharges: Variable numérica continua que representa el gasto total acumulado y pagado por el cliente durante todo su ciclo de vida comercial dentro de la organización.
- Churn: Variable categórica nominal que funge como la variable objetivo o target del proyecto, registrando si el cliente abandonó el servicio (Yes) o si permanece leal (No).

- Variables de Perfil y Servicios: Conjunto de características categóricas que describen el ecosistema del usuario, incluyendo el tipo de contrato (mensual, anual o a dos años), el método de pago (transferencia, tarjeta, factura electrónica) y los servicios digitales activos como internet de fibra óptica, soporte técnico y seguridad en línea.

### **2.3. Análisis Exploratorio de Datos (EDA)**

La fase de exploración analítica se ejecutó mediante código en Python utilizando las funciones estructurales `head()`, `info()` y `describe()` de la librería Pandas para auditar la integridad de la información. El primer hallazgo crítico surgió al evaluar la consistencia de los tipos de datos a través de `df.info()`. Mientras que las variables de antigüedad y cargos mensuales estaban correctamente tipificadas como numéricas, la columna `TotalCharges` se encontraba registrada erróneamente como un objeto de texto (`object`). Este comportamiento anómalo bloqueaba cualquier cálculo matemático o matriz de correlación.

Para solucionar este conflicto, el equipo aplicó una conversión forzada a formato numérico flotante. Este procedimiento reveló la presencia de 11 valores nulos ocultos en el dataset, los cuales consistían en espacios en blanco que el método tradicional `isnull().sum()` no había detectado inicialmente. Al cruzar estos 11 registros con la variable de antigüedad, se descubrió que todos correspondían de forma exacta a clientes con una métrica de *tenure* igual a cero meses. La presencia de estos nulos se justifica operativamente debido a que representan cuentas completamente nuevas que se incorporaron al sistema en el cierre del mes, por lo que su ciclo de facturación acumulado aún no se había ejecutado.

Posteriormente, el cálculo de la estadística descriptiva mediante `describe()` confirmó que la antigüedad promedio de la cartera de clientes es de 32.37 meses, con una desviación estándar de 24.55 meses que denota una alta dispersión en la lealtad de la base. Finalmente, la matriz de correlación lineal de Pearson permitió cuantificar matemáticamente la relación de las variables continuas con respecto al abandono. La antigüedad (*tenure*) presentó una correlación negativa moderada de -0.35, validando que a menor tiempo en la empresa, el riesgo de Churn se eleva. En contraposición, los cargos mensuales (`MonthlyCharges`) registraron una correlación

positiva de 0.19, lo que demuestra estadísticamente que las tarifas elevadas actúan como un detonante directo para la cancelación del servicio.

## **2.4. Hallazgos de las Gráficas y Visualizaciones**

Las distribuciones estadísticas y los patrones de comportamiento de los usuarios fueron proyectados cartesianamente en el entorno de Google Colab, generando cuatro conclusiones analíticas fundamentales:

En primera instancia, el Histograma de Antigüedad vs Fuga reveló un comportamiento bimodal crítico. Se observó una concentración masiva de cancelaciones de servicios durante los primeros uno a seis meses de relación comercial. Una vez superado este periodo crítico de adopción, la frecuencia de abandonos disminuye drásticamente, lo que demuestra que los esfuerzos de retención deben enfocarse quirúrgicamente en el proceso de bienvenida del cliente. En segundo lugar, el Diagrama de Caja (Boxplot) enfocado en los cargos mensuales evidenció que la mediana de los costos facturados a los clientes fugitivos es considerablemente superior en comparación con la mediana de los clientes leales. El gráfico ubica visualmente la zona de riesgo por encima de los 80 dólares mensuales, confirmando que el factor precio es una variable de alta sensibilidad para la deserción.

Asimismo, el Gráfico de Dispersión (Scatterplot) intersectó la antigüedad frente a los cargos totales acumulados. La proyección geométrica mostró una dispersión lineal ascendente donde los puntos que representan los casos positivos de Churn se agrupan densamente en la base de la pendiente; esto comprueba visualmente que el peligro operativo real se concentra en clientes jóvenes con facturaciones iniciales agresivas.

Por último, el Mapa de Calor (Heatmap) consolidó la traducción visual de la matriz de Pearson. La densidad cromática permitió al equipo descartar la presencia de multicolinealidad perfecta entre las variables predictoras continuas, validando que cada variable aporta información única y valiosa para el modelo, y autorizando el paso seguro hacia la fase de preparación de datos.



## **PREPARACIÓN DE LOS DATOS (DATA PREPARATION)**

### **3.1. Selección de Variables y Filtrado**

La fase de preparación comenzó con una depuración selectiva de las características presentes en la matriz de datos original. La decisión metodológica más importante en este punto fue la eliminación definitiva de la columna `customerID` mediante el método `df.drop()`. Al tratarse de un identificador alfanumérico único por registro, su naturaleza estadística es puramente nominal y carece de cualquier poder predictivo o varianza correlacionada con el comportamiento de los usuarios. De haberse mantenido dentro del espacio de características, los algoritmos matemáticos habrían intentado buscar patrones relacionales falsos en secuencias aleatorias de texto, lo que induce ruido innecesario en las matrices de covarianza y detona un sobreajuste prematuro en los modelos de aprendizaje.

### **3.2. Tratamiento Técnico de Valores Nulos**

Tras la conversión forzada de la variable `TotalCharges` a formato numérico flotante, se procedió a resolver la inconsistencia de los 11 valores nulos que se encontraban ocultos en forma de espacios en blanco. La decisión del equipo fue aplicar una imputación determinista, sustituyendo de forma directa dichos valores faltantes por el valor numérico absoluto de cero. Esta acción se justifica desde la lógica financiera y operativa del negocio de telecomunicaciones: como estos registros pertenecen estrictamente a clientes con cero meses de antigüedad ( $\text{tenure} = 0$ ), se deduce que son contratos recién aperturados que no han concluido su primer ciclo de facturación y, por ende, no han acumulado montos cobrados. Eliminar estas filas habría representado una pérdida de representatividad estadística de los clientes nuevos en el conjunto de entrenamiento, mientras que imputar con la media o la mediana habría inventado una deuda inexistente, alterando la distribución real de los datos.

### **3.3. Codificación de Variables Categóricas (Encoding)**

Dado que los frameworks de Machine Learning operan internamente mediante vectores numéricos y álgebra lineal, las características textuales nominales fueron

sometidas a un proceso de codificación matemática. Para la variable objetivo Churn, se realizó un mapeo binario directo, asignando el valor numérico uno a los casos de deserción ("Yes") y el valor cero a la permanencia ("No"). Para el resto de las variables categóricas explicativas (como el tipo de internet, género y tipo de contrato), se aplicó la técnica de One-Hot Encoding mediante la función `pd.get_dummies()`. Un paso crucial en este procedimiento fue la activación del parámetro `drop_first=True`, el cual descarta de forma automática la primera categoría generada para cada variable. Esta decisión es indispensable para eliminar la colinealidad perfecta —fenómeno conocido en la Ciencia de Datos como la trampa de la variable ficticia—, garantizando que ninguna columna sea una combinación lineal exacta de otra y permitiendo una optimización geométrica estable en los modelos.

### **3.4. Transformación de Datos y División Estratificada (Train/Test Split)**

Una vez unificado el dataset en tensores estrictamente numéricos, se procedió a estructurar el diseño de validación mediante la partición clásica de Hold-out, asignando el 80% de la muestra para el proceso de entrenamiento y el 20% restante para la evaluación de control independiente. Debido a que el mercado de las telecomunicaciones presenta un desbalanceo de clases inherente —donde el volumen de clientes leales supera por un amplio margen a los clientes que desertan—, el equipo ejecutó la división utilizando el parámetro de control `stratify=y`. Esta restricción matemática fuerza al algoritmo de partición a replicar de manera exacta la proporción de la tasa de Churn en ambos subconjuntos aislados. Al asegurar que tanto el set de aprendizaje como el de prueba posean la misma asimetría real, se blindó el experimento contra sesgos de muestreo aleatorio que pudieran alterar artificialmente las métricas de evaluación.

### **3.5. Normalización y Escalamiento Estándar**

La última etapa de la preparación consistió en la homogeneización escalar de los datos continuos. Los algoritmos de Machine Learning que se fundamentan en el cálculo de distancias geométricas —como KNN— o en criterios de división lineal, sufren distorsiones graves si las variables presentan magnitudes dispares, ya que características con rangos numéricos elevados dominan egoístamente el cálculo de

los gradientes o las distancias. Para mitigar este sesgo, se aplicó la transformación StandardScaler sobre las columnas continuas de antigüedad, cargos mensuales y cargos totales, centrando sus distribuciones en una media matemática de cero y una varianza unitaria de uno.

Para preservar la pureza científica del experimento y evitar el fenómeno conocido como fuga de datos (Data Leakage), el escalador ejecutó su fase de aprendizaje (fit\_transform) de manera exclusiva sobre las características del conjunto de entrenamiento. Posteriormente, al subconjunto aislado de prueba solo se le aplicó la transformación final (transform). De este modo, se garantizó matemáticamente que ningún parámetro estadístico del grupo de prueba (como su media o desviación estándar) fuera conocido por el modelo durante su entrenamiento, asegurando una simulación de entorno productivo completamente transparente y honesta.

## MODELADO Y EXPERIMENTACIÓN (MODELING)

### 4.1. Algoritmos Utilizados

Para abordar de manera robusta el problema de clasificación binaria planteado por el fenómeno del Churn, el equipo seleccionó tres familias de algoritmos de Machine Learning con fundamentos matemáticos y fronteras de decisión completamente distintas:

- K-Nearest Neighbors (KNN): Algoritmo de aprendizaje basado en instancias que no construye un modelo matemático explícito en el entrenamiento, sino que clasifica cada nuevo punto calculando la distancia geométrica (Euclidiana) en el espacio n-dimensional hacia sus vectores históricos más cercanos.
- Decision Tree Classifier (Árbol de Decisión): Modelo no paramétrico que construye reglas lógicas jerárquicas de partición. El algoritmo analiza el espacio de características y selecciona de forma iterativa los puntos de corte que maximizan la ganancia de información, utilizando el criterio de impureza de Gini para separar de forma óptima a los clientes leales de los fugitivos.
- Random Forest Classifier (Bosque Aleatorio): Arquitectura de aprendizaje ensamblado sustentada sobre el principio de agregación por arranque (Bagging). Combina múltiples árboles de decisión independientes entrenados con subconjuntos aleatorios de los datos y de las características, promediando sus vectores probabilísticos para estabilizar las predicciones del sistema.

### 4.2. Parámetros Utilizados y Experimentación Realizada

Con el objetivo de evaluar la sensibilidad de cada algoritmo y encontrar el punto de equilibrio óptimo entre el sesgo y la varianza, se diseñó una matriz experimental de 3x3 (nueve experimentos controlados en total). Para cada familia analítica, se iteró sistemáticamente sobre su hiperparámetro crítico de la siguiente manera:

- Experimentación KNN: Se modificó el número de vecinos más cercanos evaluando magnitudes impares de  $k = 3$ ,  $k = 7$  y  $k = 15$ . Controlar el parámetro  $k$  es indispensable debido a que un número muy bajo de vecinos vuelve al modelo altamente sensible al ruido y a los datos atípicos,

mientras que un valor de vecinos excesivamente alto difumina las fronteras de decisión geométrica.

- Experimentación Decision Tree: Se controló la complejidad estructural ramificada mediante el parámetro de profundidad máxima configurando los niveles `max_depth = 3`, `max_depth = 10` y `max_depth = None` (profundidad ilimitada). Restringir la profundidad actúa como un regularizador natural, impidiendo que el árbol ramifique hasta que cada hoja contenga un solo registro de entrenamiento.
- Experimentación Random Forest: Se iteró sobre el volumen de estimadores independientes en el ensamble configurando `n_estimators = 10`, `n_estimators = 50` y `n_estimators = 150`. Para garantizar una comparación justa y controlar la varianza del ensamble, se mantuvo una restricción plano-estructural fija de `max_depth = 7` en todos los subárboles del bosque.

#### **4.3. Resultados Obtenidos (Leaderboard de Modelos)**

Una vez concluida la ejecución del script analítico en el entorno de Google Colab, se extrajeron los vectores de rendimiento calculados sobre el conjunto de prueba aislado, el cual representa el 20% de la muestra total. Los nueve experimentos ejecutados fueron ordenados de forma descendente en una tabla de rendimiento general utilizando la métrica de negocio F1-Score como el criterio de optimización principal. Los resultados reales del entorno de ejecución se detallan a continuación:

**Tabla 4.1: Leaderboard General de Experimentos**

| Posición | Algoritmo Evaluado | Configuración de Parámetro        | Exactitud (Accuracy) | F1-Score (Métrica Objetivo) |
|----------|--------------------|-----------------------------------|----------------------|-----------------------------|
| 1°       | Random Forest      | n_estimators = 10, max_depth = 7  | 0.8034               | 0.5771                      |
| 2°       | KNN                | n_neighbors = 15                  | 0.7786               | 0.5726                      |
| 3°       | KNN                | n_neighbors = 7                   | 0.7708               | 0.5605                      |
| 4°       | Random Forest      | n_estimators = 150, max_depth = 7 | 0.7977               | 0.5568                      |
| 5°       | Random Forest      | n_estimators = 50, max_depth = 7  | 0.7984               | 0.5563                      |
| 6°       | KNN                | n_neighbors = 3                   | 0.7601               | 0.5481                      |
| 7°       | Decision Tree      | max_depth = 10                    | 0.7544               | 0.5286                      |

|    |               |                                 |        |        |
|----|---------------|---------------------------------|--------|--------|
| 8° | Decision Tree | max_depth = 3                   | 0.7871 | 0.4949 |
| 9° | Decision Tree | max_depth = None<br>(Ilimitado) | 0.7253 | 0.4805 |

El análisis de la experimentación real arrojó un comportamiento sumamente interesante para el equipo. Contrario a la intuición teórica inicial, el modelo de Random Forest configurado con un bosque ligero de 10 árboles consiguió el rendimiento óptimo, consolidando el *F1-Score* más alto con 0.5771 y la mejor exactitud global con el 80.34%. Este fenómeno demuestra que en el dataset de Telco, un exceso de estimadores (como el experimento de 150 árboles) indujo una sutil varianza que redujo su capacidad de generalización sobre la clase minoritaria de Churn, dejando en evidencia la necesidad de guiar las decisiones por la evidencia empírica del Leaderboard .

#### 4.4. Evidencia Técnica de la Experimentación

Para validar la correcta ejecución del código, el procesamiento de las matrices numéricas y la transparencia en la obtención del ordenamiento de los modelos, se adjunta la captura de pantalla directa obtenida en el entorno de Google Colab:

```
*** === 4.3 RESULTADOS OBTENIDOS ===
```

|          | Algoritmo     | Parámetro        | Accuracy | F1-Score |
|----------|---------------|------------------|----------|----------|
| Posición |               |                  |          |          |
| 1        | Random Forest | n_estimators=10  | 0.803407 | 0.577099 |
| 2        | KNN           | n_neighbors=15   | 0.778566 | 0.572603 |
| 3        | KNN           | n_neighbors=7    | 0.770759 | 0.560544 |
| 4        | Random Forest | n_estimators=150 | 0.797729 | 0.556765 |
| 5        | Random Forest | n_estimators=50  | 0.798439 | 0.556250 |
| 6        | KNN           | n_neighbors=3    | 0.760114 | 0.548128 |
| 7        | Decision Tree | max_depth=10     | 0.754436 | 0.528610 |
| 8        | Decision Tree | max_depth=3      | 0.787083 | 0.494949 |
| 9        | Decision Tree | max_depth=None   | 0.725337 | 0.480537 |



## EVALUACIÓN

### 5.1. Métricas Obligatorias del Modelo Campeón

La evaluación estadística del rendimiento de la arquitectura seleccionada como óptima para el negocio (Random Forest con  $n\_estimators=10$  y  $max\_depth=7$ ) se realizó analizando de forma rigurosa los resultados impresos en la consola de Google Colab:

- Exactitud (Accuracy): El modelo consolidó un valor de 0.7977 en su última ejecución de evaluación de matriz, lo que demuestra que el sistema determina correctamente el estado de permanencia o deserción en aproximadamente 8 de cada 10 clientes de la cartera.
- Precisión (Precision): Registró un valor de 0.6654, indicando que de cada 100 clientes que el algoritmo etiqueta bajo una alerta predictiva de riesgo de abandono, el 66.54% corresponden a usuarios que verdaderamente cancelarán el servicio. Esto permite blindar el uso de los recursos financieros de la empresa, evitando otorgar subsidios a clientes leales.
- Exhaustividad (Recall): Alcanzó un índice de 0.4786, estableciendo que el modelo logra interceptar de manera oportuna al 47.86% del universo real de clientes en proceso de deserción comercial.
- F1-Score: Consolidó una métrica final de 0.5568 en la celda diagnóstica, fungiendo como la media armónica estandarizada que balancea con rigor analítico la precisión y la cobertura ante la asimetría y el desbalance real de las clases del negocio.


### 5.2. Gráficas Comparativas y Diagnósticas

Para validar la estabilidad predictiva y justificar las decisiones técnicas del equipo frente a la gerencia, se integraron los paneles analíticos generados en la fase experimental. Las proyecciones cartesianas permiten contrastar las variaciones estructurales de los modelos:

- **Gráfica A (Desempeño Máximo por Algoritmo):** Demuestra visualmente los límites de aprendizaje superiores de cada familia. Aunque los tres modelos mantienen una exactitud general que ronda el 78%-80%, el colapso del *F1-Score* en

las arquitecturas individuales (como KNN) justifica matemáticamente por qué el ensamble de Random Forest es el único capaz de sostener un equilibrio operativo viable para el negocio.

- **Gráfica B (Variación del F1-Score según Configuración):** Actúa como un mapa de sensibilidad paramétrica. El gráfico de dispersión expone con claridad la alta volatilidad de los árboles de decisión individuales y la debilidad del KNN ante la alta dimensionalidad, mientras que la secuencia de puntos asignados a las variaciones de los estimadores en el Random Forest exhibe una consistencia horizontal superior.



### 5.3. Interpretación de Resultados y Comparación entre Modelos

Al poner a competir de forma directa las tres estructuras algorítmicas bajo sus respectivas variaciones de hiperparámetros, se obtuvieron conclusiones determinantes sobre la naturaleza de los datos de telecomunicaciones. El algoritmo de Vecinos Más Cercanos (KNN) evidenció una sorpresiva solidez en altas vecindades, alcanzando su segundo mejor rendimiento con 15 vecinos y un F1-Score de 0.5726, aunque decayó de forma pronunciada a medida que el valor de  $k$  disminuía debido a la influencia directa del ruido estadístico local.

Por su parte, los Árboles de Decisión demostraron el comportamiento más errático e inestable de la matriz experimental. Cuando el parámetro de profundidad se liberó sin restricciones estructurales ( $\text{max\_depth=None}$ ), el modelo sufrió de un sobreajuste severo, registrando un F1-Score rezagado de 0.4805 y la peor exactitud global con un 72.53%. Esto comprueba que un árbol individual tiende a memorizar el ruido de entrenamiento en lugar de abstraer patrones generales.

El claro ganador del diseño experimental fue el ensamble de Random Forest. Al combinar las predicciones probabilísticas de múltiples subárboles estructurados con arranque y límites de crecimiento fijos, neutralizó el ruido de fondo de la cartera de clientes, asegurando la frontera de decisión más balanceada y rentable para la organización.

#### **5.4. Análisis de Errores (Matriz de Confusión)**


La auditoría cualitativa de las predicciones absolutas y las desviaciones cometidas por el modelo final sobre los 1,409 registros del conjunto de prueba se extrae directamente de los cuadrantes de la matriz de confusión y se correlaciona con la capacidad de discriminación de la curva ROC:

La Matriz de Confusión expone que de los 1,035 clientes que mantuvieron su estatus de lealtad ("No Churn"), el modelo clasificó correctamente a 945 usuarios como Verdaderos Negativos (VN), cometiendo únicamente 90 Falsos Positivos (FP). En el contexto financiero de la operación, estos 90 casos representan desviaciones de bajo impacto económico, implicando únicamente la asignación ineficiente de un beneficio de retención a un cliente que no tenía intenciones reales de retirarse de la compañía.

Por el contrario, el desafío crítico se concentra en la diagonal inversa de la matriz. De los 374 clientes que efectivamente cancelaron sus contratos, el algoritmo interceptó con éxito a 179 usuarios como Verdaderos Positivos (VP), pero dejó pasar inadvertidos a 195 casos clasificados como Falsos Negativos (FN). Este error es el más costoso para el negocio, ya que representa clientes insatisfechos que abandonaron la organización sin que el sistema emitiera una alerta predictiva.

A pesar de esta ventana de error provocada por el desbalanceo real de los datos, la Curva ROC confirma la viabilidad institucional del proyecto al alcanzar un Área Bajo la Curva (AUC) de 0.843. Matemáticamente, un valor de  $AUC \geq 0.80$  se clasifica como una solución analítica excelente. Esto demuestra que si la gerencia comercial decide en el futuro ajustar el umbral probabilístico de decisión del modelo para priorizar la sensibilidad sobre la precisión, el algoritmo posee una alta

capacidad de separación para aislar masivamente a los clientes fugitivos, garantizando un retorno de inversión positivo ante el despliegue del sistema en producción.



## CONCLUSIONES

### ¿Qué modelo obtuvo mejor desempeño?

El modelo de ensamble Random Forest Classifier fue el ganador absoluto del proyecto integrador, demostrando una estabilidad superior para delimitar las fronteras de decisión en comparación con las arquitecturas de árboles individuales y los vecinos más cercanos.

### ¿Qué parámetros mejoraron resultados?

La configuración de 10 árboles (`n_estimators=10`) combinada con un tope de profundidad máxima de 7 (`max_depth=7`) fue la que arrojó el equilibrio operativo más eficiente en la frontera de decisión. Limitar el crecimiento vertical de los estimadores forzó al bosque a capturar únicamente las tendencias comerciales más sólidas y robustas del comportamiento de los clientes, evitando la dispersión matemática.

### ¿Existió overfitting?

Sí, se detectó de forma explícita y medible en el Árbol de Decisión individual con profundidad ilimitada (`max_depth=None`). Al no contar con restricciones de poda, el modelo memorizó los datos de entrenamiento a la perfección, provocando que al enfrentarse a los datos reales de prueba, sus métricas colapsaran al fondo del Leaderboard general.

### ¿Qué limitaciones encuentran?

La principal limitante radica en el desbalance real del dataset de telecomunicaciones, donde casi el 74% de los registros pertenecen a la clase de clientes que no abandonan la compañía. Esta asimetría severa sesga los algoritmos hacia la predicción de la clase mayoritaria, imponiendo una barrera natural al crecimiento de la exhaustividad o Recall del sistema.

### **¿Qué aprendieron del proyecto?**

Se aprendió de forma empírica que en proyectos de Ciencia de Datos aplicados a Inteligencia de Negocios, la exactitud (Accuracy) es un indicador engañoso y peligroso si se evalúa de manera aislada. El éxito y la rentabilidad de una solución predictiva real demandan el dominio conjunto del F1-Score y del Área Bajo la Curva ROC (AUC) como los verdaderos filtros de calidad estadística antes de autorizar un despliegue en entornos de producción.

## CONCLUSIÓN FINAL

Como equipo de investigación, concluimos que este proyecto abordó exitosamente la retención predictiva de clientes mediante el análisis y procesamiento de más de 7,000 registros históricos de telecomunicaciones de IBM. Tras aplicar técnicas de preprocesamiento riguroso —como la imputación de nulos, One-Hot Encoding y división estratificada—, comprobamos empíricamente que el modelo Random Forest (diez estimadores y profundidad de siete niveles) presentó la mayor robustez estadística. Al obtener una exactitud del 80.34% y un F1-Score de 0.5771, esta arquitectura mitigó eficazmente el sobreajuste masivo de los Árboles de Decisión individuales y la sensibilidad al ruido observada en algoritmos de menor complejidad como K-Nearest Neighbors.

A nivel estratégico y de negocio, nuestro análisis reveló patrones fundamentales: la deserción se concentra fuertemente en el proceso de adopción (los primeros seis meses) y en usuarios con facturaciones superiores a los ochenta dólares mensuales. Respaldado por un AUC de 0.843 y el análisis de la Matriz de Confusión, comprobamos que financieramente es preferible asumir el costo menor de un Falso Positivo (ofrecer un descuento preventivo a un cliente leal) que la pérdida irrecuperable de un Falso Negativo (ignorar a un cliente que termina cancelando). Así, este modelo se consolida como una herramienta confiable para migrar de una gestión reactiva a una proactiva, sustituyendo los subsidios masivos por campañas de fidelización altamente quirúrgicas.

La principal limitación de nuestro entorno experimental fue el severo desbalance estructural de los datos (74% de clientes leales), lo cual impuso una barrera estadística que limitó nuestra capacidad de detección al 48% de la deserción total (Recall). No obstante, esta restricción técnica nos brindó la lección analítica más valiosa del proyecto: en contextos comerciales asimétricos, la exactitud global es una métrica engañosa.

## REFERENCIAS

- IBM Cloud Pak for Data. (2020). *Telco customer churn sample dataset*. Recuperado de <https://github.com/IBM/telco-customer-churn-on-icp4d/>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Schmueli, G., & Koppius, O. R. (2011). Predictive analytics in information systems research. *MIS Quarterly*, 35(3), 553-572.
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29-39.